





Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas

Disciplina: Sistemas Operacionais I

Aula 15: Escalonamento de CPU P1

Prof. Diogo Branquinho Ramos

diogo.branquinho@fatec.sp.gov.br

São José dos Campos - SP

Roteiro

- Conceitos básicos
- Critérios de escalonamento
- Algoritmos de escalonamento



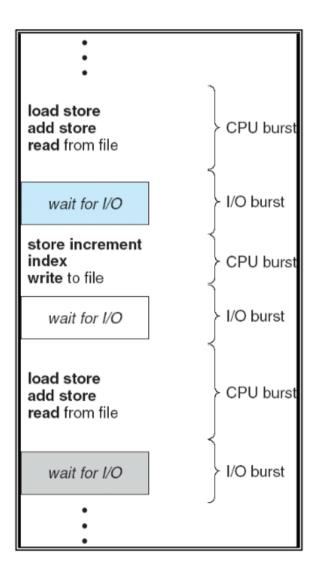
Conceitos básicos

- Necessidade de escalonar: multiprogramação!
 - Utilização máxima de CPU obtida com multiprogramação.
- Execução de um processo
 - Um ciclo de execução de CPU e espera de E/S.
 - Começa com um burst de CPU (uso de CPU), que é seguido por um burst de E/S (uso de E/S), que é seguido por um burst de CPU...



Sequência alternada de bursts de CPU e E/S

Execução típica





Histograma de tempos de burst de CPU

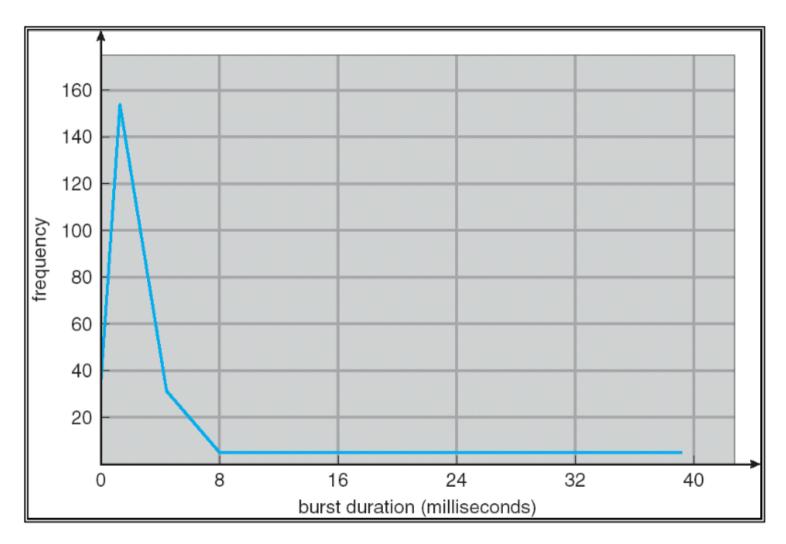
Sistema genérico

- Curva de frequência
 - Exponencial
 - Grande quantidade de bursts de CPU curtos;
 - Pequena quantidade de bursts de CPU longos.
 - I/O-bound
 - Bursts de CPU curtos (muitos).
 - CPU-bound
 - Bursts de CPU longos (alguns).
 - Essa informação pode ser importante na seleção de um algoritmo de escalonamento!



Histograma de tempos de burst de CPU

Sistema genérico





Escalonador de CPU

Quem executa?

Escalonador de curto prazo.

Funcionamento

- Seleciona dentre os processos na memória que estejam prontos para executar, e aloca a CPU a um deles.
- A fila de prontos não é necessariamente uma fila FIFO
 - Depende do algoritmo de escalonamento.
 - Os registros na fila são os PCBs.



Preempção

Definição

- Escalonamento preemptivo: o processo pode perder direito à CPU subitamente – exige hardware temporizador.
- Escalonamento n\u00e3o preemptivo: o processo libera a CPU quando termina ou se precisar de E/S.

Algumas preocupações

- Dados compartilhados entre dois processos.
 - Podem ficar em estado incoerente. Solução: sincronismo.
- Syscall preemptada: mudanças de dados do kernel.
 - SOLUÇÃO: syscall atômica. Kernel não preempta com dados em estado incoerente.



- Cada algoritmo de escalonamento possui suas propriedades peculiares.
 - A escolha de um algoritmo pode favorecer uma classe de processos em detrimento de outra.
- É preciso considerar critérios para escolher melhor algoritmo!



Utilização de CPU

- Manter a CPU a maior parte do tempo ocupada.
- Throughput (vazão)
 - # de processos que completam sua execução por unidade de tempo.
- Tempo de turnaround (tempo de retorno)
 - Quantidade de tempo para executar um processo em particular, desde o carregamento na memória até o término da execução.
 - Limitado por E/S.



Tempo de espera

- Todo o tempo em que um processo esteve esperando na fila de prontos
 - Não computa os tempos de espera por E/S.

Tempo de resposta

- Tempo desde quando uma solicitação foi submetida até a primeira reposta ser produzida. Tempo gasto para começar a responder.
 - Pode depender da chegada de dados na CPU vindos da cache ou RAM.



Equação

- Maximizar a utilização e o throughput da CPU e
- Reduzir o turnaround, o tempo de espera e o tempo de resposta.



First-Come, First-Served (FCFS)

- Fácil de implementar
- Implementação da política por meio de uma FIFO
 - O PCB do processo que entra na fila de prontos é associado ao final da fila.
 - A CPU é alocada ao processo cujo PCB está na cabeça da fila.
- Não-preemptivo
 - Processo mantém a CPU até o final.
- O tempo médio de espera geralmente não é mínimo
 - Depende dos tempos de bursts dos processos.



First-Come, First-Served (FCFS)

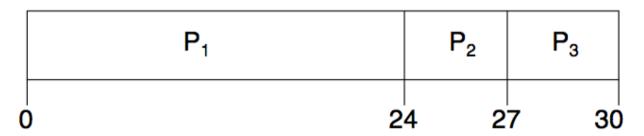
Processo Tempo de burst

P1 24

P2 3

P3 3

Suponha que os processos cheguem nesta ordem: P1 , P2 , P3. Diagrama de Gantt:



Tempo de espera para P1 = 0; P2 = 24; P3 = 27

Tempo de espera médio: (0 + 24 + 27)/3 = 17

First-Come, First-Served (FCFS)

- Suponha que os processos cheguem nesta ordem: P2, P3, P1
- O diagrama de Gantt para o escalonamento é:



- Tempo de espera para P1 = 6; P2 = 0; P3 = 3
- Tempo de espera médio: (6 + 0 + 3)/3 = 3
- Muito melhor que o caso anterior!
 - Varia muito para bursts variados.
- Efeito comboio: processo curto atrás de processo longo.
 - Um processo CPU-bound, vários processos I/O bound.
 - Solução: priorizar processos I/O bound no uso de CPU.

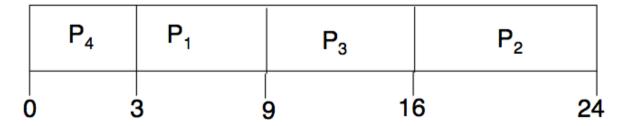
Shortest Job First (SJF)

Funcionamento

 Associa a cada processo o tamanho de seu próximo burst de CPU, para escalonar o processo com o menor tempo.

Processo	Tempo de burst
P1	6
P2	8
P3	7
P4	3

Como ficaria?



Shortest Job First (SJF)

- Tempo de espera médio SJF: 7,00
- Tempo de espera médio FCFS: 10,25
- SJF é melhor!
 - Provê o menor tempo de espera médio.
 - Estratégia: mover um processo curto antes de um longo diminui mais o tempo de espera do processo curto do que aumenta o tempo de espera de um processo longo.
 - Equação: $\frac{3a+2b+c}{4}$

Modificação no algoritmo SJF: preempção

Shortest-Remaining-Time-First (SRTF)

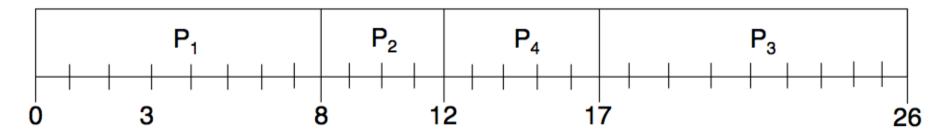
- Novo esquema
 - Preemptivo: se um novo processo chega com tamanho de burst de CPU menor que o tempo restante do processo atualmente em execução, a CPU é alocada.
- Até agora os processos chegam juntos.
 - E se eles chegassem em tempos diferentes?



Exemplo de SJF

Processo	Tempo chegada	Tempo de burst
P1	0	8
P2	1	4
P3	2	9
P4	3	5

SJF

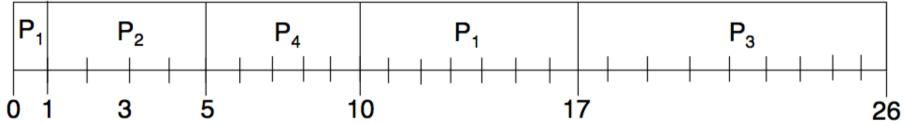


• Tempo médio de espera = (0 + 7 + 9 + 15)/4 = 7,75

Exemplo de SRTF

Processo	Tempo chegada	Tempo de burst
P1	0	8
P2	1	4
P3	2	9
P4	3	5

SRTF

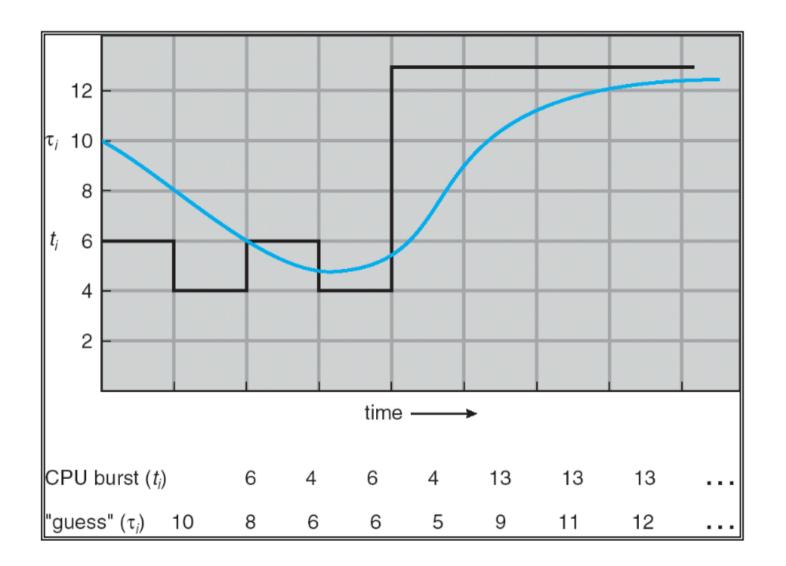


• Tempo médio de espera = ((0 + 9) + 0 + 15 + 2)/4 = 6,5

Tamanho do próximo burst de CPU

- Como saber o tamanho do burst de CPU antes de executar?
 - Através de estimativa usando o tamanho dos bursts de CPU anteriores e a média exponencial.
 - 1. t_n = extensão real do nth burst de CPU
 - 2. τ_{n+1} = valor previstopara o próximo burst de CPU
 - 3. α , $0 \le \alpha \le 1$
 - 4. Define: $\tau_{n+1} = \alpha t_n + (1-\alpha)\tau_n$.

Previsão do próximo burst de CPU



Escalonamento por prioridade

- Um número inteiro é associado a cada processo.
- A CPU é alocada ao processo com a maior prioridade (menor inteiro ≡ maior prioridade).
 - Preemptivo
 - Não preemptivo
- SJF é um escalonamento por prioridade
 - Será o desempate entre processos com mesma prioridade.
- Prioridades
 - Internamente: uma quantidade mensurável (limites de tempo, memória, número de arquivos abertos...).
 - Externamente: fora do SO (importância do processo, quantidade paga pelo uso da CPU, fatores políticos...).



Escalonamento por prioridade

Problema: Estagnação (Starvation)

- Processos com baixa prioridade podem nunca ser executados.
 - O IBM 7094 no MIT foi desativado em 1973 e tinha um processo de baixa prioridade submetido em 1967 ainda não executado!

Solução: Envelhecimento (Aging)

- À medida que o tempo passa, aumenta a prioridade do processo.
 - Um processo de prioridade 127 (baixa) chega à prioridade 0 (alta) em quase 32 horas, se sua prioridade aumentar em 1 a cada 15 min.

